

2차 프로젝트 진행 정리 — 이커머스 고객 이탈 예측

작성 시점: 데이터 선정 완료(Online Retail II), 정식 EDA 재구성 직전

1. 프로젝트 개요

- **주제:** 고객 이탈(churn) 예측 — 이커머스 도메인
 - **데이터:** Online Retail II (UCI 공식, CC BY 4.0) — 영국 도매상 실거래 로그 2년
 - **목표:** 퀄리티 최우선. 성능 수치 경쟁이 아니라 **검증 프로세스·해석·활용 설계의 깊이**로 차별화
 - **필수 산출물:** 전처리 결과서, 학습 결과서, 저장된 최종 모델(Pipeline), Streamlit 시연, README/발표자료
 - **가이드 핵심 요구:** 예측 시점·Target 명확화 / Train·Val·Test 분리(Test 최종 1회) / 전처리+모델 단일 Pipeline / Streamlit은 저장 모델 로드 / 이탈 Recall 우선 평가
 - **협업:** GitHub 공유, 어떤 환경에서도 재현 가능한 코드 (kagglehub 자동 다운로드, 경로 하드코딩 금지, requirements.txt)
-

2. 데이터 개요 및 구조

Kaggle 미러([mashlyn/online-retail-ii-uci](https://kaggle.com/mashlyn/online-retail-ii-uci))로 kagglehub 로드.

- **1,067,371행 × 8열**, 2009-12-01 ~ 2011-12-09 (약 2년), 43개국 (UK 91.9%)
- 계층 구조: 상품 라인 1,067,371 → 주문(Invoice) 53,628 → 고객 5,942명 — **한 행 ≠ 고객** → 고객 이탈 예측을 위해 라인 → 고객 단위 집계가 프로젝트의 중심 작업
- **타깃 컬럼 없음** → InvoiceDate(시간축) 기반으로 직접 정의
- 컬럼: Invoice(주문번호, 'C' 접두=취소), StockCode(상품코드), Description, Quantity, InvoiceDate, Price, CustomerID(결측 22.8%), Country

3. 기술통계 — 극단값의 정체

- **구매-취소 쌍:** Quantity ±80,995가 동일 상품·동일 고객·연번 인보이스(581483/C581484) — 대량 주문 후 통째 취소
- **비상품 행 혼재:** StockCode에 M(수기 입력), BANK CHARGES, AMAZONFEE 등 회계성 코드 / "thrown away" 등 내부 폐기 기록 (Price 극대값들의 정체)
- 실데이터의 극단값은 각각 "사건"이며 도메인 규칙으로 해석·처리 가능

4. 데이터 정제 깔때기

단계	제거	잔여
전체 라인	—	1,067,371
취소 인보이스('C') 제외	-19,494	1,047,877
비상품 StockCode 제외	-4,885	1,042,992
수량·가격 ≤0 제외	-6,116	1,036,876
CustomerID 결측 제외	-234,244	802,632 (75.2%)

"결측 = 비회원 구매" 가설 3중 검증 (통과)

- 1. 인보이스 53,628건 중 ID 존재 **0건** (전부 있음 44,876 / 전부 없음 8,752) → 주문 단위 현상
- 2. 25개월 상시 존재(평균 22.9%) + 홀리데이 시즌(12~1월) 급증 → 일회성 선물 구매객 패턴
- 3. 구매 행태 차이: ID 없음(수량 중앙값 1, 단가 £3.36, UK 98.8%) vs ID 있음(수량 5, £1.95, UK 90.3%) → **비회원 = 소매 소비자 / 회원 = 도매(B2B) 고객** 구조 확인

제외 논리: 매출 분석이면 포함 대상이지만, "특정 고객이 이후에도 구매하는가"라는 과제에서 고객 특정 불가 행은 질문 자체가 불성립 → 분석 모집단을 **회원(도매) 고객 5,878명**으로 정의. 데이터 손실이 아니라 분석 단위에 따른 범위 설정.

(기록: 당초 결측 다수를 내부 기록으로 추정했으나 분해 결과 96.4%가 정상 구매 형태(비회원)로 확인 — 가설 수정 사례)

5. 시간축 분석 — 이탈 라벨 정의의 근거

- 월별 주문·활성 고객: 2년 내내 안정 + 9~11월 성수기 (도매의 홀리데이 대비 재고 확보) / 2011-12 급락은 부분 월(12/9 종료) 때문 — 해석 주의 플래그
- **재구매 간격 분포** (30,742건): 중앙값 25일, 75% 지점 62일, 90% 지점 135일 / mean 51.7 » median 25.0 → 강한 오른쪽 꼬리 분포
- **윈도우별 이탈률** (기준일 이전 1년 내 활성 고객 대상, 예측 구간 내 무구매 = 이탈):

예측 구간	이탈률
60일	55.6%
90일	49.2%
120일	46.4%

- 90일 = 재구매 분포 75~90% 지점 사이 → **분포에서 도출된 정의** (비율 역산 아님)

- 이탈률 49.2% ≈ 균형 → 샘플링·가중치 불필요, 모든 평가지표 정상 작동
- 타깃 비율은 데이터의 속성이 아니라 **질문(정의)의 속성**: "활성 도매 고객이 향후 90일 내 재주문하지 않을 확률"

6. 주제 승인 기준 7문항 대조

질문	판정	근거
데이터 확보 가능?	✓	kagglehub 한 줄, 이미 로드 완료
Target 코드화 가능?	✓	라벨링 코드 작성 완료 (~15줄)
미래 정보 제거 가능?	✓	시간 분할 구조상 유입 경로 차단
표본 충분?	✓	90일 기준 대상 ~4.3천 명, 이탈률 49.2%
개인정보·라이선스?	✓	UCI 공식(CC BY 4.0), 익명 ID만 존재
Streamlit 가능?	✓	저장 Pipeline 로드 + 고객별 위험도 조회
실제 행동 연결?	✓	B2B 고객별 구매액 기반 비용-편익 threshold

7. 확정된 규칙 (코드화)

- `src/data.py`
 - `load_raw()`: kagglehub 다운로드 + 컬럼명 정리(`Customer ID` → `CustomerID`) + `InvoiceDate` datetime 변환
 - `load_sales()`: 정제 깔때기 규칙 코드화 — 취소 제외, 상품코드 패턴(`^\d{5}[A-Za-z]*$`) 필터, 수량·가격>0, ID 보유
 - 검증 기준값: 802,632행 / 고객 5,878명 근처
- 라벨 정의(안): 기준일 이전 365일 내 구매 이력 보유 고객 대상, **기준일 이후 90일 내 무구매 = 이탈(1)**

8. 남은 작업 로드맵

1. **repo 정비**: `src/data.py` 커밋, 검증 셀들을 `01_eda_log.ipynb` (로그 레벨 EDA)로 정식 재구성
2. **1부 EDA 마무리** (로그 레벨): 상품·국가·금액 분포, 고객당 주문 수 분포 — 치우친 분포·로그 변환 검토
3. **고객 스냅샷 생성**: 기준일 규칙 확정 → 관찰 구간 데이터만으로 고객 단위 집계 (RFM + 파생)
4. **2부 EDA** (고객 레벨): 생성 피처 × 이탈률 분위 분석, 신호 판별, 상관 분석
5. 전처리 결과서 → Test 분리 → Pipeline 베이스라인 (로지스틱 vs 트리, 피쳐셋 비교 실험)
6. 해석(SHAP)·비용 기반 threshold → Streamlit → 학습 결과서·발표자료